

ólica2.1015    únicacamada2.1216    únicacamada2.1316

UNIVERSIDADE CÂNDIDO MENDES

CHRYSTIANO BARBOSA DE SOUZA ARAÚJO  
LEANDRO MORAES VALE CRUZ  
LUCAS CARVALHO  
THIAGO RIBEIRO NUNES

# DEFINIR O TÍTULO

Campos dos Goytacazes - RJ  
Junho - 2009

JÔNATAS OLIVEIRA LOPES SOARES  
MAYCON BARRETO LOPES  
WALLACE GOMES DE SOUZA

# MÓDULO DE MAPEAMENTO DO TOOLKIT HÓRUS

Monografia apresentada à Universidade  
Cândido Mendes como requisito obrigatório  
para a obtenção do grau de Bacharel em  
Ciências da Computação.

ORIENTADOR: Prof. D.Sc. Ítalo Matias

CO-ORIENTADOR: Prof. D.Sc. Dalessandro Soares

Campos dos Goytacazes-RJ  
2009

JÔNATAS OLIVEIRA LOPES SOARES  
MAYCON BARRETO LOPES  
WALLACE GOMES DE SOUZA

**MÓDULO DE MAPEAMENTO DO TOOLKIT  
HÓRUS**

Monografia apresentada à Universidade  
Cândido Mendes como requisito obrigatório  
para a obtenção do grau de Bacharel em  
Ciências da Computação.

Aprovada em \_\_\_\_ de \_\_\_\_\_ de 2009.

**BANCA EXAMINADORA**

---

Prof. D.Sc. Ítalo Matias - Orientador  
Doutor pela UFRJ

---

Prof. D.Sc. Dalessandro Soares  
Doutor pela PUC-Rio

---

Prof. BLABLABLA  
Univeridade de Londres



# Agradecimentos



# Resumo

Palavras-chave: MAPEAMENTO, LOCALIZAÇÃO, SIMULTANEOUS LOCALIZATION AND MAPPING, SLAM, TOOLKIT, AGENTE INTELIGENTE.

# Abstract

Keywords: MAPPING, LOCALIZATION, SIMULTANEOUS LOCALIZATION AND MAPPING, SLAM, TOOLKIT, HÓRUS, INTELIGENT AGENT.

# Sumário

<b>1</b>	<b>Introdução</b>	<b>6</b>
<b>2</b>	<b>Inteligência Computacional</b>	<b>7</b>
2.1	Agentes Inteligentes . . . . .	7
2.2	Reconhecimento de Padrões . . . . .	7
2.3	Redes Neurais Artificiais . . . . .	9
2.3.1	Neurônio Biológico . . . . .	10
2.3.2	O Neurônio Artificial MCP . . . . .	12
2.3.3	Funções de Ativação . . . . .	13
2.3.4	Arquiteturas de Redes Neurais . . . . .	15
2.4	Visão Computacional . . . . .	19
2.4.1	Extração de características . . . . .	20
2.4.2	OCR . . . . .	23
<b>3</b>	<b>Conclusões e Trabalhos Futuros</b>	<b>24</b>

# Lista de Figuras

2.1	Neurônio biológico . . . . .	10
2.2	Modelo do neurônio de McCulloch e Pits . . . . .	12
2.3	Figura Somatorio . . . . .	13
2.4	Equacao funcao linear . . . . .	13
2.5	Gráfico da função Limiar . . . . .	14
2.6	GFuncao Sigmoides . . . . .	14
2.7	Gráfico da função sigmóide . . . . .	14
2.8	GFuncao Signum . . . . .	15
2.9	Gráfico da função Signum . . . . .	15
2.10	GFuncao Hiperbólica . . . . .	15
2.11	Gráfico da Tangente Hiperbólica . . . . .	16
2.12	Redes de uma única camada . . . . .	16
2.13	redes de múltiplas camadas . . . . .	16
2.14	Exemplo de rede feedback. . . . .	17
2.15	esquema de aprendizado supervisionado. . . . .	18
2.16	esquema de aprendizado não supervisionado. . . . .	19
2.17	Matriz de pixel de um bitmap. . . . .	22
2.18	layout com seis regiões em três linhas e duas colunas. . . . .	22
2.19	Quatorze diferentes tipos de arestas . . . . .	22
2.20	Matrizes referentes aos tipos de arestas . . . . .	23
2.21	Quatorze diferentes tipos de arestas . . . . .	23

# Lista de Tabelas

!

# Capítulo 1

## Introdução

## Capítulo 2

# Inteligência Computacional

### 2.1 Agentes Inteligentes

### 2.2 Reconhecimento de Padrões

Reconhecimento de padrões é uma atividade que os humanos fazem a todo tempo e, normalmente, sem um esforço consciente. Seres humanos recebem informações através de vários sensores orgânicos, as quais são processadas instantaneamente pelo cérebro. Essa habilidade é ainda mais impressionante no que diz respeito à assertividade do processo de reconhecimento mesmo quando as informações não se encontram em condições ideais, como por exemplo, em situações onde as informações são vagas, imprecisas, ou até mesmo, incompletas. A área de Reconhecimento de Padrões é responsável por projetar algoritmos e abordagens que procuram aproximar as tarefas realizadas computacionalmente das habilidades humanas. Esse processo consiste em classificar e descrever objetos através de um conjunto de características ou propriedades. Um dos principais conceitos dentro de reconhecimento de padrões é o discriminante. Tal conceito consiste em medir uma distância de



um determinado padrão para cada outro previamente conhecido. Logo, a classe de um determinado padrão será a mesma do seu vizinho mais próximo [Simp 92], [Simp 93], de menor distância ou o protótipo mais parecido [Torb 98]. Espera-se de um sistema de reconhecimento de padrões que este seja capaz de aprender de uma forma adaptativa e dinâmica. Em sistemas de reconhecimento de padrões automáticos, as etapas de aprendizagem e reconhecimento são combinados a fim de atingir um objetivo desejado [Cagn 93] [Valli 98]. Portanto, redes neurais artificiais é uma das principais técnicas utilizadas nesse sentido [Nigr 93] e será apresentada na seção seguinte. Um típico sistema de reconhecimento de padrão consiste em três partes: aquisição de dados, seleção/extração de características e classificação/clustering [Pattern recognition book].

- Aquisição de dados: é o processo de seleção dos dados que serão usados como entrada no processo de reconhecimento. Tais dados podem ser qualitativos, quantitativos ou ambos. Podendo ser numéricos, linguísticos, entre outros.
- Seleção/Extração de características: o objetivo principal desta etapa consiste em gerar o melhor conjunto de características necessárias para o processo de reconhecimento, de modo a maximizar a eficácia do sistema. A grande dificuldade dessa etapa está na determinação de um critério adequado para a escolha de um bom conjunto de características. Um bom critério é aquele que é imutável para qualquer variação possível dentro de uma classe, todavia, deve ser capaz de destacar as diferenças importantes a fim de discriminar entre diferentes tipos de padrões.
- Classificação/clustering: classificação é o processo de definição de qual classe um determinado padrão de entrada pertence. Essa classificação

pode ser feita utilizando técnicas determinísticas e probabilísticas. As classes são definidas a partir de um conjunto de amostras apresentadas na etapa de aprendizagem.

A técnica de reconhecimento de padrões possui uma grande variedade de aplicações. Dentre elas, pode-se citar: reconhecimento de faces, leitura biométrica, identificação de circuitos impressos defeituosos, reconhecimento óptico de caracteres, reconhecimento de fala e de escrita cursiva, entre outros.

## 2.3 Redes Neurais Artificiais

Redes Neurais Artificiais (RNAs) são estruturas computacionais que visam imitar a forma com que o cérebro humano processa as informações. O cérebro possui a capacidade de organizar e encadear seus elementos estruturais, conhecidos como neurônios, para realizar o processamento das informações de forma não linear e paralela. Dessa forma, as principais características das redes neurais são a habilidade de aprender relações complexas e não lineares entre os padrões de entrada e as saídas, utilizarem procedimentos de treinamento seqüencial e se auto-adaptar aos dados [2].

Na sua forma geral, uma rede neural é uma máquina projetada para imitar a forma com que o cérebro realiza uma tarefa particular ou uma função de interesse, podendo ser implementada em hardware ou simulada através de software. Para atingir uma performance razoável, as redes neurais empregam uma massiva interconexão de unidades de processamento simples, denominadas neurônios [1].

As redes neurais possuem a capacidade de aprendizado e, como consequência, de generalização. Generalização refere-se à produção de saídas racionais para entradas que não foram apresentadas a rede durante a fase de

treinamento ou aprendizado. As capacidades de aprendizado e de generalização tornam as redes neurais capazes de resolver problemas complexos e não-lineares. A seguir, serão explicadas algumas características do neurônio biológico, fundamentais para o entendimento das RNAs.

### 2.3.1 Neurônio Biológico

O sistema nervoso é formado por um conjunto extremamente complexo de neurônios. Os neurônios estão conectados uns aos outros através de sinapses. Nos neurônios a comunicação é realizada através de impulsos elétricos, quando um impulso é recebido, o neurônio o processa, e passado um limite de ação, dispara um segundo impulso o qual flui do corpo celular para o axônio que, por sua vez, pode ou não estar conectado a um dendrito de outra célula. A Figura 1 apresenta uma representação de um neurônio.

Figura 2.1: Neurônio biológico

Os principais componentes de um neurônio são:

- Os dendritos: membrana que recebe os estímulos gerados por outras células. Os dendritos são as entradas do neurônio.
- Soma: é o corpo do neurônio, que é responsável por coletar e combinar informações vindas de outros neurônios;
- O axônio: membrana constituída de uma fibra tubular que é responsável por transmitir os estímulos para outras células. O axônio representa a saída do neurônio.

O neurônio biológico é constituído de um corpo celular denominado soma. Nesse Local ocorre o processamento metabólico da célula nervosa ou neurônio. A partir da soma, projetam-se extensões filamentosas denominadas dendritos, e o axônio. Este modelo anatômico foi identificado por Ramon Cajal em 1894. Com base nas pesquisas de Erlanger e Gasser, em 1920, e outras posteriores, passou-se a entender o comportamento do neurônio biológico como sendo o dispositivo computacional do sistema nervoso, o qual possui muitas entradas e uma única saída.

As entradas ocorrem através das conexões sinápticas, que conectam a árvore dendrital aos axônios de outras células nervosas. Os sinais que chegam pelos dendritos são pulsos elétricos conhecidos como impulsos nervosos ou potenciais de ação, e constituem a informação que o neurônio processará de alguma forma para produzir como saída um impulso nervoso no seu axônio.

Sinapse é o nome dado ao ponto de contato entre a terminação axônica de um neurônio e o dendrito de outro. É pelas sinapses que os nodos se unem funcionalmente, formando a rede neural. As sinapses funcionam como válvulas, e são capazes de controlar a transmissão de impulsos entre os nodos na rede [3] e estão compreendidas entre duas membranas celulares: a membrana pré-sináptica, que recebe o estímulo vindo de uma célula, e a membrana pós-sináptica, que é a do dendrito. Na região pré-sináptica, se o estímulo nervoso recebido atinge um determinado limiar em um espaço curto de tempo, a célula "dispara", produzindo um impulso que é transferido para outras células através de neurotransmissores presentes na membrana dendrital. Dependendo do neurotransmissor, a conexão sináptica é excitatória ou inibitória. A conexão excitatória provoca uma alteração no potencial da membrana que contribui para formação do impulso nervoso no axônio de saída, enquanto que a conexão inibitória age no sentido contrário.

O mecanismo como é criado o potencial de ação ou impulso nervoso é o seguinte: quando o potencial da membrana está menos eletronegativo do que o potencial de repouso, diz-se que a membrana está despolarizada e quando está mais negativo, diz-se que ela está hiperpolarizada. O impulso nervoso ou potencial de ação é uma onda de despolarização de certa duração de tempo, que se propaga ao longo da membrana. A formação de um potencial de ação na membrana axonal ocorre quando essa membrana sofre despolarização suficientemente acentuada para cruzar um determinado valor conhecido como limiar de disparo. Quando esse limiar é superado, os estímulos são passados para outras células através das ligações sinápticas.

### 2.3.2 O Neurônio Artificial MCP

McCulloch e Pits [4] propuseram um modelo matemático do neurônio artificial MCP. Esse modelo foi proposto com base nos principais conceitos do neurônio biológico. O modelo matemático do neurônio proposto por McCulloch e Pits apresenta  $n$  terminais de entrada  $x_1, x_2, \dots, x_n$  (representando os dendritos) e apenas um terminal de saída  $y$  (representando o axônio). Os terminais de entrada do neurônio têm pesos acoplados  $w_1, w_2, \dots, w_n$  cujos valores podendo ser positivos ou negativos dependendo de as sinapses correspondentes serem inibitórias ou excitatórias. O efeito de uma sinapse particular  $i$  no neurônio pós-sináptico é dado por  $x_i w_i$ . Os pesos determinam o nível em que o neurônio deve considerar sinais de disparo que ocorrem naquela conexão. Uma descrição do modelo está ilustrada na Figura 2.

Figura 2.2: Modelo do neurônio de McCulloch e Pits

O corpo do neurônio realiza um simples somatório dos valores  $x_i w_i$  que chegam a ele. Se o somatório dos valores ultrapassa o limiar de ativação ou  $\text{threshold}$ , o neurônio dispara (valor 1 na saída), caso contrário o neurônio permanece inativo (valor 0 na saída). A ativação do neurônio é realizada através de uma função de ativação, que dispara ou não o neurônio dependendo do valor da soma ponderada das suas entradas. No modelo MCP original, a função de ativação ativar a saída quando:

Figura 2.3: Figura Somatorio

Na equação acima,  $n$  é a quantidade de entradas do neurônio,  $w_i$  é o peso associado à entrada  $x_i$  e  $\theta$  é o limiar do neurônio.

### 2.3.3 Funções de Ativação

A partir do modelo apresentado por McCulloch e Pits, surgiram vários outros modelos que permitem a produção de qualquer saída, não apenas zero ou um, e com várias funções de ativação. As funções de ativação mais comuns são:

- Função Limiar: função utilizada no modelo de McCulloch e Pits, caracterizada por "tudo ou nada", representada da seguinte forma:

Figura 2.4: Equacao funcao linear

Onde  $v$  é igual ao valor produzido pelo somatório das entradas do neurônio.

áfico da função Limiar.eps

Figura 2.5: Gráfico da função Limiar

- Função Sigmóide: essa é uma função semilinear, limitada e monotônica que pode assumir valores entre 0 e 1. Existem várias funções sigmodais, porém, a mais usada é a função logística definida pela equação abaixo:

Figura 2.6: GFuncao Sigmoide

Onde  $a$  é o parâmetro de inclinação da função sigmóide e  $v$  é o valor de ativação do neurônio.

áfico da função sigmóide.eps

Figura 2.7: Gráfico da função sigmóide

- Função Signum: essa função apresenta as mesmas características da função limiar, porém, se limita ao intervalo entre 1 e -1. Essa função é representada por:

Onde  $b$  são os limites inferiores e superiores ( $b = -1$  no gráfico) e  $v$  é o valor de ativação.

- Tangente Hiperbólica: seu gráfico é parecido com o da Função Sigmóide, assumindo valores entre 1 e -1, sendo representada por:

Onde  $a$  é o parâmetro de inclinação da curva,  $b$  são os limites inferiores e superiores ( $b = -1$  no gráfico) e  $v$  o valor de ativação.

Figura 2.8: GFuncao Signum

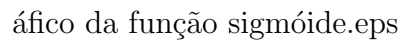
Gráfico da função sigmóide. A imagem não é visível, apenas o nome do arquivo é fornecido.

Figura 2.9: Gráfico da função Signum

### 2.3.4 Arquiteturas de Redes Neurais

A definição da arquitetura de uma RNA define a maneira com que os neurônios são estruturados na rede [1]. A arquitetura restringe o tipo de problema que pode ser tratado pela rede. Redes com uma camada única de nodos MCP, por exemplo, só conseguem resolver problemas linearmente separáveis. Redes recorrentes, por sua vez, são mais apropriadas para resolver problemas que envolvem processamento temporal [3]. A arquitetura de uma rede é definida pelos seguintes parâmetros: número de camadas da rede, número de neurônios em cada camada, tipo de conexão entre os neurônios e topologia da rede.

Em geral, as redes neurais podem ser classificadas quanto ao número de camadas, quanto ao tipo de conexão e quanto à conectividade entre os neurônios. Quanto ao número de camadas têm-se:

- Redes de uma única camada: existe apenas um nó entre uma entrada e uma saída da rede. A Figura 3 apresenta dois exemplos de redes de única camada.

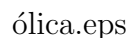
Gráfico da função hiperbólica. A imagem não é visível, apenas o nome do arquivo é fornecido.

Figura 2.10: GFuncao Hiperbólica



áficoTangenteólica.eps

Figura 2.11: Gráfico da Tangente Hiperbólica

de uma única camada.eps

Figura 2.12: Redes de uma única camada

- Redes de múltiplas camadas: existe mais de um neurônio entre alguma entrada e alguma saída (Figura 4).

Figura 2.13: redes de múltiplas camadas

Quanto ao tipo de conexão têm-se:

- Feedforward, ou acíclica: a saída de um neurônio na  $i$ -ésima camada da rede não pode ser usada como entrada de nodos em camadas de índice menos ou igual a  $i$  (Figura 4).
- Feedback, ou cíclica: a saída de algum neurônio na  $i$ -ésima camada da rede é utilizada como entrada em neurônios da camada de índice menor ou igual a  $i$  (Figura 5).

Quanto à conectividade têm-se:

- \* Redes parcialmente conectadas (Figura 4).
- \* Redes completamente conectadas (Figura 3).

sectionProcesso de aprendizado A principal propriedade de uma rede neural é a sua habilidade de aprender sobre o ambiente no qual está inserida de forma a melhorar a sua performance na resolução de problemas complexos. Essa melhora na performance é

Figura 2.14: Exemplo de rede feedback.

adquirida a cada instante do processo de aprendizado de acordo com uma forma de medição pré-estabelecida. Com isso, uma rede neural aprende sobre seu ambiente através de um processo iterativo de ajuste dos pesos sinápticos adquirindo mais conhecimento sobre o problema após cada iteração do processo de aprendizado. Segundo Mendel e McLaren [4], no contexto de redes neurais, aprendizado é o processo pelo qual os parâmetros de uma rede neural são ajustados através de estímulos produzidos pelo ambiente no qual a rede está inserida. O tipo de aprendizado é determinado pela maneira particular com que os parâmetros são modificados. Foram desenvolvidos diversos métodos de treinamento de redes, podendo ser agrupados em dois paradigmas principais: aprendizado supervisionado e aprendizado não-supervisionado. No entanto, outros dois paradigmas bastante conhecidos são os de aprendizado por reforço (que é um caso particular de aprendizado supervisionado) e aprendizado por competição (que é um caso particular de aprendizado não supervisionado).

- \* **Aprendizado Supervisionado** Esse tipo de aprendizado é o mais utilizado em RNAs. Esse aprendizado é dito supervisionado porque as entrada e as respectivas saídas desejadas são fornecidas por um supervisor externo, normalmente chamado de "professor". Seu objetivo é ajustar os pesos da rede, de forma a encontrar uma ligação entre os pares de entrada e saída fornecidos pelo professor. O professor é responsável por

direcionar o processo de aprendizado fornecendo os padrões de entrada, as saídas desejadas e a taxa de erro desejada. A cada padrão de entrada submetido à rede pelo professor, compara-se a resposta desejada (que representa uma solução ótima para aquele padrão de entrada) com a resposta calculada, ajustando-se os pesos das conexões para minimizar o erro. A minimização da diferença é incremental, já que pequenos ajustes são feitos nos pesos a cada iteração do aprendizado. A soma dos erros quadráticos de todas as saídas é normalmente utilizada como medida de desempenho da rede e também como função de custo a ser minimizada pelo algoritmo de treinamento. A Figura 6 apresenta um esquema básico de aprendizado supervisionado.

Figura 2.15: esquema de aprendizado supervisionado.

Nesse trabalho, o algoritmo de aprendizado utilizado nesse trabalho foi o backpropagation.

- \* **Aprendizado Não Supervisionado.** No aprendizado não supervisionado não há um professor que oriente o processo de aprendizado. Ao contrário do aprendizado supervisionado, que possui pares de entrada e saída, para esses algoritmos, somente são disponibilizados os padrões de entrada. De acordo com as regularidades estatísticas com que as entradas ocorrem, a rede cria classes de acordo com as características extraídas de cada padrão de entrada. Dessa forma, para cada entrada fornecida a rede, a saída será a classe a qual a entrada pertence. Caso a entrada não pertença a nenhuma classe pré-existente, a rede

cria uma nova classe para essa entrada. A base para a utilização desse tipo de aprendizado é a redundância nos dados, sem redundância, seria praticamente impossível a utilização bem sucedida do aprendizado não supervisionado. A Figura 7 apresenta uma esquema de um sistema de aprendizado não supervisionado.

Figura 2.16: esquema de aprendizado não supervisionado.

A estrutura do sistema de aprendizado não supervisionado pode adquirir uma variedade de formas diferentes. Como exemplo de arquitetura, pode-se considerar uma rede como uma camada de entrada, uma camada de saída, conexões feedforward da entrada para a saída e conexões laterais dos neurônios da camada de saída. Outro exemplo é uma rede feedforward com múltiplas camadas, em que a livre organização procede na base de camada por camada. Nestes dois exemplos, o processo de aprendizado consiste em modificar repetidamente o peso sináptico de todas as conexões do sistema em resposta às entradas.

## 2.4 Visão Computacional

Breve comentario sobre visao computacional!!!!!!!!!!!!!!

### 2.4.1 Extração de características

No campo de reconhecimento de padrões, extrair características significa extrair medidas associadas ao objeto que se deseja reconhecer, de forma que essas medidas sejam semelhantes para objetos semelhantes e diferentes para objetos distintos [Santos 2007]. Definir vetores de características é o método para representação de dados mais comum e conveniente para problemas de classificação e reconhecimento. Cada característica resulta de uma medição qualitativa ou quantitativa, que é uma variável ou um atributo do objeto [Guyon et al., 2006]. Para reconhecer um caractere de uma representação bitmap, há a necessidade de extrair características do mesmo para descrevê-lo de uma forma mais apropriada para o seu processamento computacional e reconhecimento. Como o método de extração de características afeta significativamente a qualidade de todo o processo de reconhecimento de padrões, é muito importante extrair características de modo que elas sejam invariantes no que diz respeito às várias condições de iluminação, tipo de fonte e possíveis deformações dos caracteres causadas, por exemplo, pela inclinação da imagem.

Geralmente, a descrição de uma região de uma imagem é baseada em suas representações interna e externa. A representação interna de uma imagem é baseada em suas propriedades regionais, como cor ou textura. A representação externa é selecionada quando se deseja dar ênfase nas características da forma do objeto. Logo, o vetor de características de uma representação externa inclui características como o número de linhas, a quantidade de arestas horizontais, verticais e diagonais, etc.

O conjunto de vetores de características forma um espaço vetorial. Cada caractere representa uma determinada classe, e todas as formas de representação desse caractere definem as instâncias dessa classe. Todas as instâncias do mesmo caractere devem ter uma descrição similar através de vetores numéricos chamados de "‘descritores’", ou "‘padrões’". Logo, vetores suficientemente próximos representam o mesmo caractere. Essa é a premissa básica para que o processo de reconhecimento de padrões seja bem sucedido.

Nas sessões seguintes, serão explicados alguns métodos de extração de características implementados no toolkit horus.

- \* Matriz de Pixel

A maneira mais simples de extrair características de um bitmap é associar a luminância de cada pixel com um valor numérico correspondente no vetor de características.

Esse método, apesar de simples, possui alguns problemas que podem torná-lo inadequado para o reconhecimento de caracteres. O tamanho do vetor é igual à altura do bitmap multiplicado pela sua largura, portanto, bitmaps grandes produzem vetores de características muito longos, o que não é muito adequado para o reconhecimento. Logo, o tamanho do bitmap é uma restrição para esse método. Além disso, este método não considera a proximidade geométrica dos pixels, bem como suas relações com a sua vizinhança. No entanto, este método pode ser adequado em situações onde o bitmap do caractere se encontra muito opaco ou muito pequeno para a detecção de arestas.

- \* Histograma de Arestas por Regiões

Figura 2.17: Matriz de pixel de um bitmap.

Esse método extrai o número de ocorrências de determinados tipos de arestas em uma região específica do bitmap. Isso torna o vetor de características desse método invariante com relação à disposição das arestas em uma região e a pequenas deformações do caractere. Sendo o bitmap representado pela função discreta  $f(x, y)$ , largura  $w$  e altura  $h$ , onde  $0 \leq x < w$  e  $0 \leq y < h$ . Primeiramente é realizada a divisão do bitmap em seis regiões ( $r_0, r_1, \dots, r_5$ ) organizadas em três linhas e duas colunas. Quatro layouts podem ser utilizados para a divisão do bitmap em regiões. Definindo a aresta de um caractere

Figura 2.18: layout com seis regiões em três linhas e duas colunas.

como uma matriz 2X2 de transições de branco para preto nos valores dos pixels, tem-se quatorze diferentes tipos de arestas, como ilustrado na figura 4.

Figura 2.19: Quatorze diferentes tipos de arestas

O vetor de ocorrências de cada tipo de aresta em cada sub-região da imagem é normalmente muito longo o que não é uma boa prática em reconhecimento de padrões, onde o vetor de características deve ser tão menor quanto possível. Com isso, pode-se agrupar tipos de arestas semelhantes para reduzir o tamanho do vetor de características. Por questões de simplicidade, o agrupamento dos tipos de aresta será desconsiderado

no algoritmo de extração de características. Sendo  $n$  igual ao número de tipos de arestas diferentes, onde  $h_i$  é uma matriz  $2 \times 2$  que corresponde ao tipo específico de aresta, e  $p$  igual ao número de regiões retangulares em um caractere têm-se:

Figura 2.20: Matrizes referentes aos tipos de arestas

O vetor de características de saída é ilustrado pelo padrão abaixo. A notação  $h_j@r_i$  significa "número de ocorrências de um tipo de aresta representado pela matriz  $h_j$  na região  $r_i$ ":

Figura 2.21: Quatorze diferentes tipos de arestas

## 2.4.2 OCR



## Capítulo 3

# Conclusões e Trabalhos Futuros